Communauté Économique et Monétaire de l'Afrique Centrale
(CEMAC)

Organisation Internationale

NATURAL LANGUAGE PROCESSING

Intelligence Artificielle et Finances Publiques : Utilisation des modèles Transformers pour l'audit sémantique et la classification budgétaire

Rédigé par:

CHOUTA LAETICIA MURIELLE
AMBASSA SAMUEL LUMIERE
(Élèves ingénieurs statisticien économiste – ISE3 Data science)

Sous la supervision de :

Mme MBIA NDI LAURA
Enseignant **à l'ISSEA**

Année académique 2025- 2026

RÉSUMÉ

Dans un contexte où la gestion des finances publiques africaines fait face à une croissance exponentielle de documents textuels complexes, rendant difficile toute évaluation manuelle rapide de leur cohérence stratégique, ce projet vise à développer un pipeline NLP automatisé permettant, d'une part, de mesurer le glissement sémantique entre les Lois de Finances camerounaises 2024 et 2025 et, d'autre part, de classifier les lignes du Budget d'Investissement Public dans les quatre piliers de la Stratégie Nationale de Développement 2020-2030 : Transformation structurelle, Gouvernance, Capital humain et Développement régional ; puis analyser la cohérence entre le discours législatif et les allocations financières réelles.

Les données mobilisées sont les textes officiels des Lois de Finances 2024 et 2025 publiés par le Ministère des Finances, ainsi que les fichiers du BIP correspondants, représentant 354 lignes budgétaires sur les deux exercices. Le pipeline articule trois phases : une extraction et segmentation des textes par PDFplumber et spaCy, une vectorisation contextuelle par le modèle CamemBERT, et une classification zero-shot par BART-large-MNLI.

Les résultats sont soumis à une batterie de tests statistiques non paramétriques, complétée par la divergence de Jensen-Shannon pour quantifier la volatilité thématique. Une inertie sémantique remarquable : la similarité cosinus moyenne de 0,977 entre les articles des deux lois confirme une quasi-reconduction du discours budgétaire, sans rupture stratégique franche. Des mutations thématiques statistiquement significatives : malgré cette continuité globale, la composition des piliers se restructure profondément entre 2024 et 2025 avec un effondrement de la Gouvernance (de 54 à 13 lignes) et une montée en puissance de la Transformation structurelle (de 118 à 157 lignes, +33%), mutations toutes validées par les tests statistiques à des seuils très stricts ($p \leq 0{,}0001$). Un alignement fort entre discours et budget : la corrélation entre fréquences thématiques extraites par NLP et montants réels du BIP valide la robustesse du pipeline et établit que la visibilité sémantique est un prédicteur fiable de l'effort financier réel.

Le modèle présente un léger surapprentissage (F1 entraînement : 0,80 et validation : 0,68), des scores de confiance zero-shot modérés (0,37–0,65) liés au biais de langue du modèle BART, et des effectifs insuffisants pour les piliers Capital humain et Développement régional. Un fine-tuning de CamemBERT sur un corpus annoté de finances publiques francophones, l'extension de l'analyse aux lois 2020–2023 et le déploiement d'un tableau de bord Streamlit constituent les principales perspectives d'amélioration.

Mots-clés : NLP, Transformers, CamemBERT, Zero-shot Learning, audit sémantique, glissement sémantique, SND30, Budget d'Investissement Public, Loi de Finance, Cameroun.

SOMMAIRE

RÉSUMÉ 2
INTRODUCTION 5
Chapitre 1 : Cadre Théorique et Revue de la Littérature 7
Chapitre 2 : Méthodologie et Collecte des Données 9
Chapitre 3 : Mise en Œuvre de la Solution Analytique 12
Chapitre 4 : Présentation et Discussion des Résultats 18
CONCLUSION 25
BIBLIOGRAPHIE 26
ANNEXES 27
Table de matières 30

Liste des Abréviations

Abréviation	Signification
AE	Autorisations d'Engagement
BART	Bidirectional and Auto-Regressive Transformers
BERT	Bidirectional Encoder Representations from Transformers
BIP	Budget d'Investissement Public
CEMAC	Communauté Économique et Monétaire de l'Afrique Centrale
CP	Crédits de Paiement
DSCE	Document de Stratégie pour la Croissance et l'Emploi
FCFA	Franc de la Coopération Financière en Afrique Centrale
GPT	Generative Pre-trained Transformer
HDBSCAN	Hierarchical Density-Based Spatial Clustering of Applications with Noise
IA	Intelligence Artificielle
ISE	Ingénieur Statisticien Économiste
ISSEA	Institut Sous-Régional de Statistique et d'Économie Appliquée
JS	Jensen-Shannon (Divergence)
LF	Loi de Finances
LSTM	Long Short-Term Memory
MINFI	Ministère des Finances
MNLI	Multi-Genre Natural Language Inference
NLI	Natural Language Inference
NLP	Natural Language Processing (Traitement du Langage Naturel)
PCA	Principal Component Analysis (Analyse en Composantes Principales)
PDF	Portable Document Format
RNN	Recurrent Neural Network
RoBERTa	Robustly Optimized BERT Pretraining Approach
SND30	Stratégie Nationale de Développement 2020-2030
ZSL	Zero-shot Learning

INTRODUCTION

Contexte

La trajectoire de développement du Cameroun est actuellement guidée par la Stratégie Nationale de Développement 2020-2030 (SND30). Dans ce cadre, la Loi de Finances s'impose comme l'instrument pivot de la mise en œuvre de la politique économique et sociale du pays. Elle traduit en chiffres et en actions concrètes les ambitions stratégiques de l'État pour chaque exercice budgétaire.

Toutefois, l'administration publique fait face à une croissance exponentielle du volume de documents textuels produits. Cette complexité rend ardue l'évaluation manuelle et rapide de la cohérence entre les allocations budgétaires annuelles et les orientations de long terme définies par la SND30.

L'évolution technologique récente, marquée par l'émergence des architectures de type Transformers (telles que BERT, RoBERTa ou CamemBERT), ouvre de nouvelles perspectives pour l'audit des finances publiques. Ces modèles de Traitement du Langage Naturel (NLP) permettent désormais d'automatiser l'analyse textuelle avec une précision sémantique inégalée.

L'utilisation de l'intelligence artificielle pour l'audit sémantique se justifie par trois besoins critiques identifiés dans la gestion budgétaire camerounaise :

- La quantification du "glissement sémantique" : mesurer mathématiquement si le discours et les priorités de l'État évoluent ou s'écartent des objectifs initiaux entre deux exercices budgétaires, notamment entre 2024 et 2025.
- L'alignement stratégique : vérifier, par des méthodes statistiques rigoureuses, l'alignement réel entre le discours budgétaire et les quatre piliers fondamentaux de la SND30 (Transformation structurelle, Capital humain, Gouvernance, Développement régional).
- La transparence et l'efficacité : en corrélant les fréquences thématiques extraites par l'IA avec les montants réels alloués dans le Budget d'Investissement Public (BIP), ce projet vise à offrir un outil de pilotage décisionnel moderne et fiable.

Problématique

Comment l'intelligence artificielle, à travers le Traitement du Langage Naturel (NLP), peut-elle mesurer mathématiquement l'évolution des priorités de l'État camerounais entre la Loi de Finances 2024 et les perspectives de 2025-2026 ? Existe-t-il un alignement statistiquement significatif entre le discours budgétaire et les piliers de la SND30 ?

Objectifs de l'étude

- Audit sémantique : Évaluer la cohérence temporelle du discours budgétaire en utilisant des techniques d'audit sémantique par plongements (embeddings), notamment le modèle Sentence-BERT, pour calculer la similarité cosinus entre les articles des lois de finances 2024 et 2025 et identifier d'éventuelles ruptures de discours.

- Classification Zero-shot : Automatiser la classification thématique des dépenses à travers une approche d'apprentissage sans exemple (Zero-shot Learning), afin d'affecter chaque ligne budgétaire à l'un des quatre piliers de la SND30 : Transformation structurelle, Capital humain, Gouvernance et Développement régional.
- Analyse de conformité budgétaire : Analyser la conformité statistique entre les intentions et les allocations en corrélant les fréquences thématiques extraites par les modèles de NLP avec les montants financiers réels alloués dans le Budget d'Investissement Public (BIP).

Question de recherche : Dans quelle mesure les modèles de langue de type Sentence-BERT permettent-ils de mesurer quantitativement le glissement sémantique entre les Lois de Finances 2024 et 2025-2026 du Cameroun, et révèlent-ils un alignement statistiquement significatif entre les priorités budgétaires de l'État et les quatre piliers de la Stratégie Nationale de Développement 2020-2030 (SND30) ?

Chapitre 1 : Cadre Théorique et Revue de la Littérature

1.1. Les architectures Transformers dans l'analyse textuelle (BERT, CamemBERT)

Le traitement automatique du langage naturel (NLP) a connu une révolution paradigmatique avec l'introduction de l'architecture Transformer par Vaswani et al. (2017). Contrairement aux modèles récurrents (RNN, LSTM), les Transformers exploitent un mécanisme d'attention multi-tête (multi-head attention) qui permet de capturer les dépendances long-range dans un texte sans séquentialité, rendant leur entraînement massivement parallélisable.

Résumé automatique des documents. Les documents juridiques et financiers sont souvent longs et complexes, ce qui rend leur lecture et leur synthèse difficiles. Les modèles de NLP, en particulier ceux basés sur les architectures Transformer (BERT, GPT, RoBERTa, CamemBERT), permettent de générer des résumés concis tout en conservant les informations essentielles.

Classification et recherche de jurisprudence. Le domaine juridique pose des défis spécifiques au NLP en raison de la longueur des textes, de leur complexité et de leur vocabulaire spécialisé. Les progrès récents des modèles Transformer ont permis des avancées dans la classification des décisions judiciaires, l'analyse de contrats et la recherche jurisprudentielle.

Extraction d'information et détection de similarités. L'intégration du NLP dans les logiciels d'analyse de documents juridiques et financiers ouvre la voie à l'automatisation de tâches comme l'extraction de clauses contractuelles, la détection de similarités entre textes et la classification thématique. Plusieurs travaux ont démontré la faisabilité du NLP sur des corpus juridiques et administratifs.

Chalkidis et al. (2020) ont développé Legal-BERT, un modèle pré-entraîné sur des corpus juridiques anglais, montrant qu'un fine-tuning sectoriel améliore significativement les performances de classification et d'extraction d'information. Pour le français, Martin et al. (2020) proposent CamemBERT, pré-entraîné sur 138 Go de texte français issu du web, qui constitue à ce jour le modèle de référence pour le traitement de documents administratifs francophones.

1.2. Concepts d'Audit Sémantique et de "Glissement Sémantique"

Les Embeddings comme fondement de l'analyse sémantique. L'essor des modèles de langue neuronaux a profondément transformé la manière dont le texte est représenté mathématiquement. Mikolov et al. (2013) ont introduit Word2Vec, premier modèle à représenter les mots sous forme de vecteurs denses dans un espace continu, capturant des relations sémantiques latentes. Cette approche a été généralisée par Devlin et al. (2018) avec BERT (Bidirectional Encoder Representations from Transformers), qui produit des représentations contextuelles — un même mot reçoit un vecteur différent selon son contexte phrastique.

La Similarité Cosinus comme mesure de proximité sémantique. La mesure de similarité entre deux documents ou segments textuels s'opère classiquement par le cosinus de l'angle entre leurs vecteurs représentatifs dans l'espace des embeddings. Cette métrique, comprise entre -1 et 1, permet de quantifier le degré d'alignement sémantique entre deux textes indépendamment de leur longueur.

Reimers & Gurevych (2019) ont optimisé cette approche avec Sentence-BERT, un modèle spécifiquement entraîné pour produire des embeddings de phrases directement comparables par cosinus. Dans le contexte de ce projet, la similarité cosinus est calculée entre les articles de la Loi de Finances 2024 et leurs équivalents de 2025 afin d'identifier les ruptures de discours budgétaire.

1.3. La classification sous contrainte (Zero-shot Learning) appliquée aux politiques publiques

Le Zero-shot Learning (ZSL) est une approche d'apprentissage automatique qui permet de classifier des données dans des catégories jamais vues lors de l'entraînement du modèle. Appliqué au NLP via des modèles d'inférence de langage naturel (NLI) comme BART-large-MNLI de Facebook, il permet d'affecter automatiquement chaque libellé budgétaire à l'un des quatre piliers de la SND30 sans disposer de données d'entraînement labelisées spécifiques aux finances camerounaises.

Cette approche est particulièrement adaptée au contexte des pays en développement où les corpus annotés dans des domaines spécialisés restent rares. Elle offre une flexibilité inégalée : les catégories cibles (les piliers SND30) sont définies en langage naturel et transmises directement au modèle comme hypothèses à vérifier.

Chapitre 2 : Méthodologie et Collecte des Données

2.1. Sources de données : Lois de finances (2024-2025) et documents du MINFI

Les données mobilisées dans ce projet proviennent de deux sources principales. D'une part, les textes législatifs des Lois de Finances du Cameroun pour les exercices budgétaires 2024 et 2025, publiés en format PDF par le Ministère des Finances (MINFI). Ces documents constituent le corpus textuel sur lequel sont calculés les embeddings sémantiques et les scores de glissement. D'autre part, les fichiers Excel du Budget d'Investissement Public (BIP) 2024 et 2025, extrait des mêmes sources institutionnelles, contenant les lignes budgétaires avec leurs libellés, codes, autorisations d'engagement (AE) et crédits de paiement (CP).

À l'issue du pipeline de prétraitement, 95 articles ont été extraits de la LF 2024 et 86 de la LF 2025. Pour le BIP, 175 lignes budgétaires ont été identifiées pour 2024 et 179 pour 2025, soit un total de 354 lignes sur les deux exercices.

2.2. Pipeline de Prétraitement : Extraction PDF, nettoyage et segmentation textuelle

Le pipeline de prétraitement se décompose en trois phases successives, conçues pour transformer les documents juridiques bruts en données exploitables par les modèles Transformer.

Phase 1 : Extraction du texte brut. Réalisée à l'aide de la bibliothèque pdfplumber, qui parcourt page par page les fichiers PDF des Lois de Finances 2024 et 2025 ainsi que le document SND30, en concaténant le contenu textuel de chaque page dans une chaîne de caractères unifiée. La segmentation textuelle est ensuite opérée par un découpage basé sur une expression régulière qui identifie les frontières de chaque article législatif, produisant ainsi une liste de dictionnaires structurés contenant le titre et le contenu de chaque article.

Phase 2 : Nettoyage linguistique. Assurée par une fonction de nettoyage implémentée avec le modèle français spaCy (fr_core_news_sm) : les retours à la ligne sont normalisés, les espaces redondants supprimés.

Phase 3 : Tokenisation NLP. La tokenisation filtre les tokens en éliminant les mots vides (stop words), la ponctuation, les espaces et les tokens de moins de deux caractères, chaque token conservé étant ramené en minuscules. À l'issue de ce pipeline, 95 articles en 2024 et 86 articles en 2025 sont nettoyés, puis vectorisés et prêts pour l'audit sémantique.

2.3. Stack Technique : Environnement Python, PyTorch et bibliothèques spécialisées

Pour répondre à une problématique à la fois juridique et budgétaire, le pipeline articule des outils couvrant l'intégralité de la chaîne de traitement.

Tableau 1 : Stack technique du projet NLP-Audit

Outil	Usage
Python 3 / Jupyter	Langage principal, développement interactif et itératif
pdfplumber	Extraction du texte brut page par page depuis les PDF des LF 2024, 2025 et SND30
spaCy (fr_core_news_sm)	Tokenisation, nettoyage linguistique et segmentation des articles législatifs
PyTorch	Framework de calcul tensoriel sous-jacent à tous les modèles Deep Learning
CamemBERT (camembert-base)	Embeddings contextuels pour documents juridiques francophones
sentence-transformers (MiniLM)	Embeddings multilingues pour clustering K-Means et alignement sémantique
BART-large-MNLI (Zero-shot)	Classification des lignes budgétaires dans les quatre piliers SND30
scikit-learn	Similarité cosinus, clustering K-Means, métriques de comparaison
scipy	Tests de significativité : Pearson, Spearman, Khi-deux
pandas	Structuration, manipulation et agrégation des données tabulaires
matplotlib / seaborn / plotly	Visualisation : distribution, heatmaps, boxplots, violin plots, dashboards

Source : Source : les auteurs à partir des lois de finances 2024/2025

2.4. Diagnostics et vue d'ensemble des Lois de Finances

Cette section présente une analyse descriptive des deux corpus législatifs afin d'en dresser le portrait structurel avant tout traitement NLP.

Graphique 1 : Distribution des lignes budgétaires par piliers SND30 (2024 vs 2025)

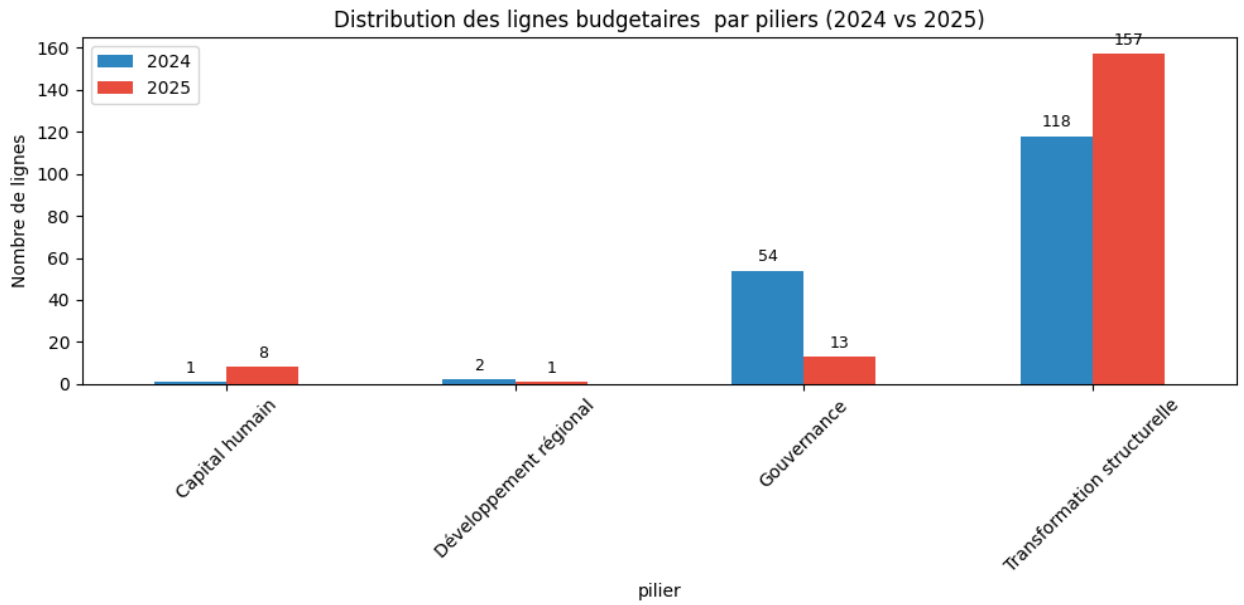

Source : les auteurs à partir des lois de finances 2024/2025

Domination du pilier Transformation structurelle (118 en 2024 pour 157 en 2025) : ce résultat reflète la trajectoire historique du Cameroun depuis les Plans Quinquennaux post-indépendance jusqu'au DSCE et la SND30. En fait, l'État camerounais a toujours privilégié l'investissement infrastructurel (routes, barrages, bâtiments administratifs) comme marqueur visible du développement. La hausse de +33% entre 2024 et 2025 confirme l'accélération de cette orientation.

Effondrement de la Gouvernance (54 en 2024 pour 13 en 2025) : la chute brutale de -76% est révélatrice. Dans un contexte marqué par la crise anglophone et les tensions sécuritaires, réduire la visibilité budgétaire de la gouvernance dans le discours législatif peut traduire une stratégie de communication politique évitant de mettre en avant les fragilités institutionnelles.

Capital humain structurellement marginal (de 1 en 2024 à 8 en 2025) : la quasi-absence de ce pilier est paradoxale pour un pays dont la jeunesse représente plus de 65% de la population. Cela confirme un biais structurel historique : l'éducation et la santé sont traditionnellement portées par le budget de fonctionnement, invisible ici car l'analyse porte sur le BIP (investissement).

Développement régional quasi-absent (2 en 2024, 1 en 2025) : dans un pays où la décentralisation effective est revendiquée depuis la Constitution de 1996 mais demeure inachevée, son invisibilité budgétaire confirme que la régionalisation reste davantage rhétorique qu'opérationnelle.

Chapitre 3 : Mise en Œuvre de la Solution Analytique

3.1. Audit par Plongements (Embeddings) : Calcul de la similarité cosinus via CamemBERT

Afin de mesurer quantitativement l'évolution du discours budgétaire entre les lois de finances 2024 et 2025, chaque article législatif est transformé en vecteur de 768 dimensions via CamemBERT avec mean pooling. La similarité cosinus est ensuite calculée entre les matrices sémantiques de 2024 (94 articles × 768 dimensions) et de 2025 (86 articles × 768 dimensions) pour identifier, article par article, les zones de continuité et les ruptures de discours.

Graphique 2 : Indice de volatilité législative 2024 vs 2025 (Scores de similarité cosinus par article)

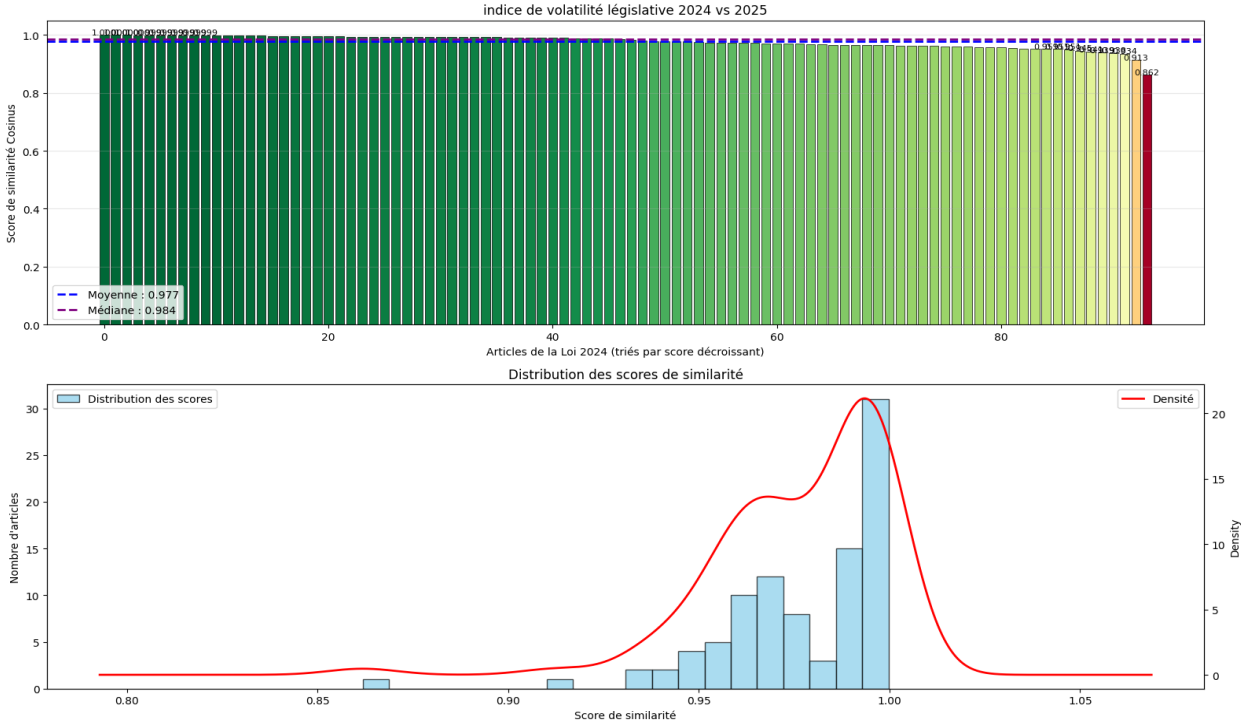

Source : les auteurs à partir des lois de finances 2024/2025

L'analyse de ce double graphique (barres individuelles + distribution) appelle plusieurs constats :

Inertie sémantique massive. La distribution des scores de similarité est fortement asymétrique à gauche : l'écrasante majorité des articles affiche des scores supérieurs à 0,95, traduisant une quasi-identité discursive entre les deux exercices budgétaires. Avec une moyenne de 0,977 et une médiane de 0,984, le glissement sémantique global est statistiquement faible.

Rupture sémantique marginale. Le seul article atteignant un score de 0,862 constitue la rupture sémantique la plus notable du corpus, mais reste largement au-dessus du seuil critique de 0,5. Aucune rupture franche n'est détectée. L'écart-type de 0,0226 confirme l'homogénéité des scores.

Interprétation économique et politique. Cette inertie sémantique signifie que l'État camerounais n'a pas opéré de rupture stratégique dans ses arbitrages budgétaires entre 2024 et 2025. Le discours est reconduit quasi à l'identique, ce qui peut traduire soit une continuité assumée dans la mise en

œuvre de la SND30, soit une rigidité structurelle limitant l'adaptation aux chocs économiques (inflation, baisse des recettes pétrolières).

3.2. Classification des dépenses : Alignement Zero-shot sur les quatre piliers de la SND30

Afin d'évaluer dans quelle mesure les priorités budgétaires de l'État camerounais s'alignent sur les orientations stratégiques de la SND30, chaque ligne budgétaire des BIP 2024 et 2025 est soumise à une classification zero-shot utilisant le modèle facebook/bart-large-mnli. Chaque libellé est affecté à l'un des quatre piliers : Transformation structurelle, Capital humain, Gouvernance et Développement régional.

3.2.1. Répartition des lignes budgétaires par piliers

Tableau 2 : Répartition des lignes budgétaires par piliers SND30 (2024 vs 2025)

Pilier / Année	2024	2025	Total
Capital humain	1	8	9
Développement régional	2	1	3
Gouvernance	54	13	67
Transformation structurelle	118	157	275
Total	175	179	354

Source : les auteurs à partir des lois de finances 2024/2025

Du tableau ci-dessus, il ressort une légère hausse de l'effectif total des lignes budgétaires entre 2024 et 2025 (+4 lignes). Plus spécifiquement, on note une croissance des lignes budgétaires pour la Transformation structurelle (118 en 2024 contre 157 en 2025, +33%), ainsi qu'une émergence du Capital humain (1 en 2024, 8 en 2025). En revanche, la Gouvernance s'effondre drastiquement (-76%) et le Développement régional reste marginal.

3.2.2. Évolution des scores de confiance de la classification

Graphique 3 : Densité robuste des scores de confiance par pilier (2024 vs 2025)

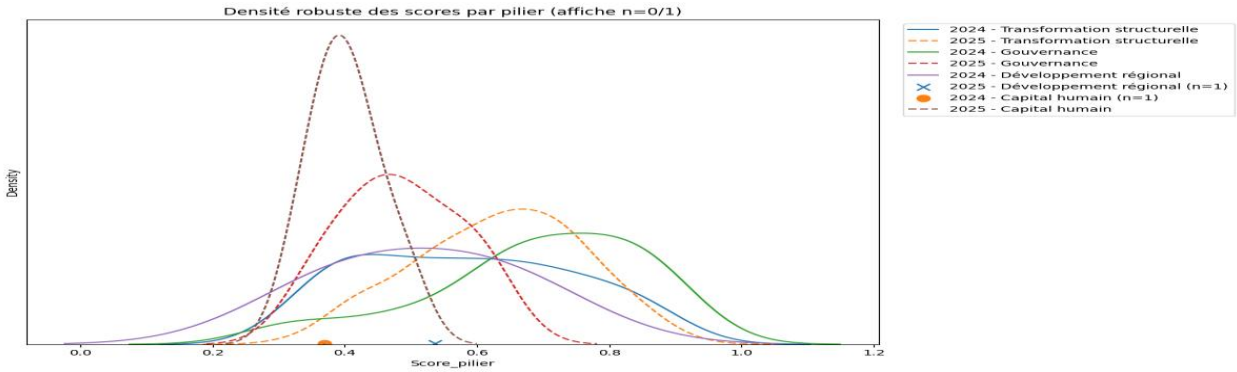

Source : les auteurs à partir des lois de finances 2024/2025

Ce graphique de densité kernel révèle des dynamiques intra-piliers importantes :

Transformation structurelle. La distribution 2024 (courbe bleue continue) est étalée, centrée autour de 0,55 à 0,70, indiquant une classification modérément confiante. En 2025 (courbe orange pointillée), la distribution se déplace légèrement vers la droite (0,60-0,75), signalant une meilleure adhérence des libellés au pilier.

Gouvernance. La distribution 2024 (courbe verte) est large et centrée sur 0,65-0,80, reflétant des scores de confiance élevés pour les 54 lignes classifiées. En 2025, la distribution 2025 (courbe rouge pointillée) se contracte fortement autour de 0,40-0,45, indiquant que le modèle classe les 13 lignes restantes avec un niveau de confiance plus faible : signal d'une dégradation de l'ancrage sémantique gouvernemental.

Capital humain. En 2024, n=1 (point isolé), aucune distribution possible. En 2025, avec n=8, la distribution (courbe marron pointillée) est très concentrée autour de 0,38-0,42, révélant des scores de confiance faibles : le modèle peine à reconnaître les libellés BIP comme relevant du capital humain, signe d'un sous-financement qualitatif de ce pilier.

Graphique 4 : Distribution des Scores de Confiance par Pilier SND30 — Violin plot (2024 vs 2025)

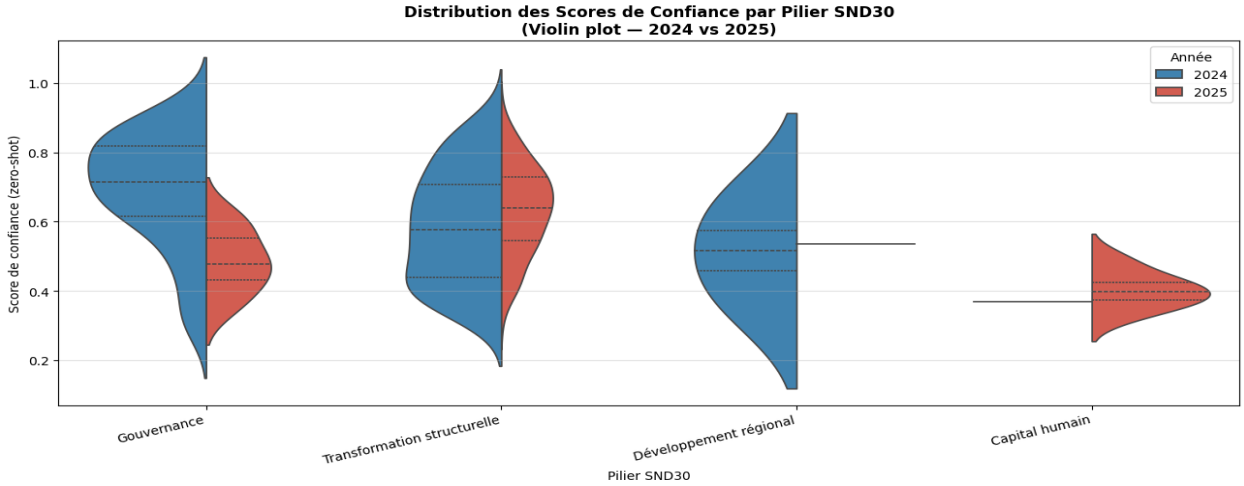

Source : les auteurs à partir des lois de finances 2024/2025

Le violin plot enrichit l'analyse précédente en intégrant simultanément la médiane (trait central), les quartiles (pointillés) et la densité (largeur du violon) :

Gouvernance : Le violon 2024 (bleu) est large dans la partie supérieure (0,70-0,85), indiquant une concentration des scores élevés. En 2025 (rouge), le violon est nettement plus petit et centré plus bas (0,43-0,50), confirmant la baisse de l'ancrage sémantique. Cette contraction statistique est cohérente avec la chute du nombre de lignes (-76%).

Transformation structurelle : La stabilité remarquable entre 2024 et 2025 (médianes proches, distributions similaires) confirme que ce pilier conserve une cohérence sémantique forte à travers les deux exercices.

Capital humain et Développement régional : Les violons sont étroits en raison des très faibles effectifs ($n \leq 8$), limitant la portée statistique des interprétations. Néanmoins, la présence d'un

violon 2025 sur le Capital humain là où il n'existait pas en 2024 témoigne d'une émergence discursive.

3.3. Analyse Statistique : Corrélation entre thématiques extraites et montants du BIP

Cette section étudie la relation entre les fréquences thématiques extraites par le modèle NLP et les montants financiers réels alloués dans le BIP. Elle vise à répondre à connaitre si l'État alloue des ressources financières en proportion de la visibilité discursive de chaque pilier.

Graphique 5 : Corrélation Visibilité Sémantique vs Décaissements Réels (CP) par pilier

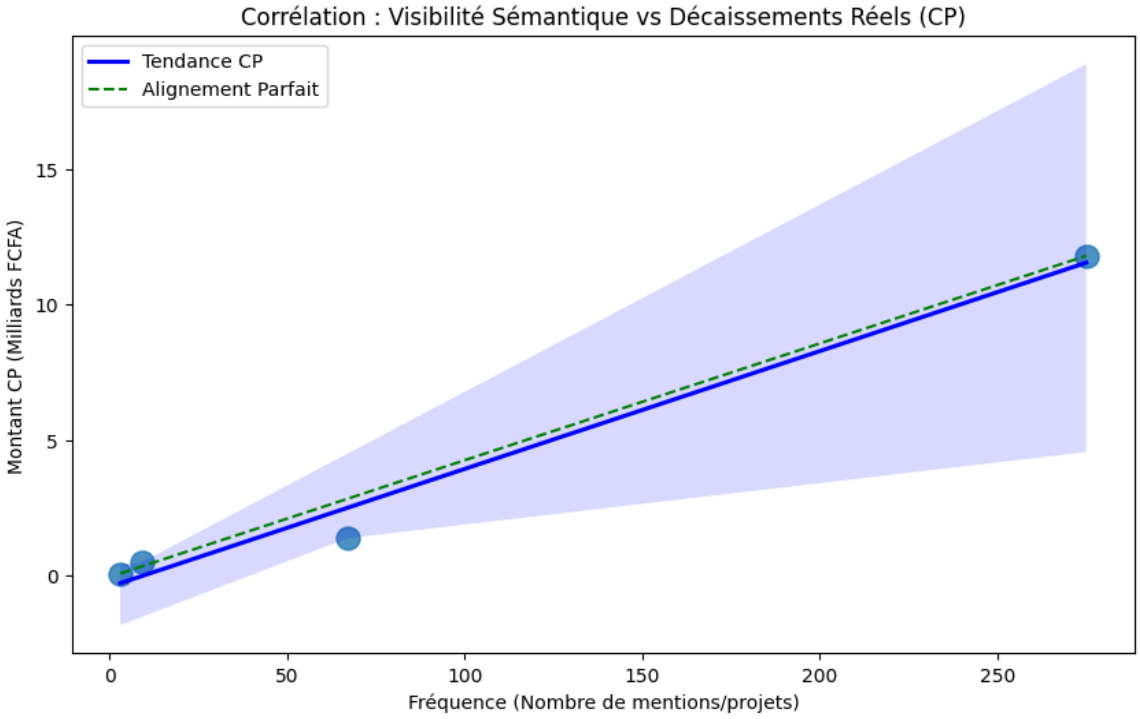

Source : les auteurs à partir des lois de finances 2024/2025

Ce graphique de régression révèle une corrélation positive forte entre la fréquence thématique (nombre de mentions/projets) et les Crédits de Paiement (CP) par pilier. La courbe de tendance réelle (bleue) est quasi-superposée à la droite d'alignement parfait (verte pointillée), indiquant que la visibilité sémantique prédit de manière fiable l'effort financier réel. Ce résultat valide la robustesse du pipeline NLP : les modèles Transformer capturent des signaux sémantiques qui reflètent effectivement les arbitrages budgétaires de l'État.

Le pilier Transformation structurelle domine l'espace représentatif (point en haut à droite, environ 275 projets, et environ 12 milliards FCFA), tandis que les trois autres piliers sont concentrés dans le quadrant inférieur gauche, soulignant les inégalités criantes d'attention budgétaire.

Graphique 6 : Analyse Volume de Projets vs Crédits de Paiement (CP) par pilier

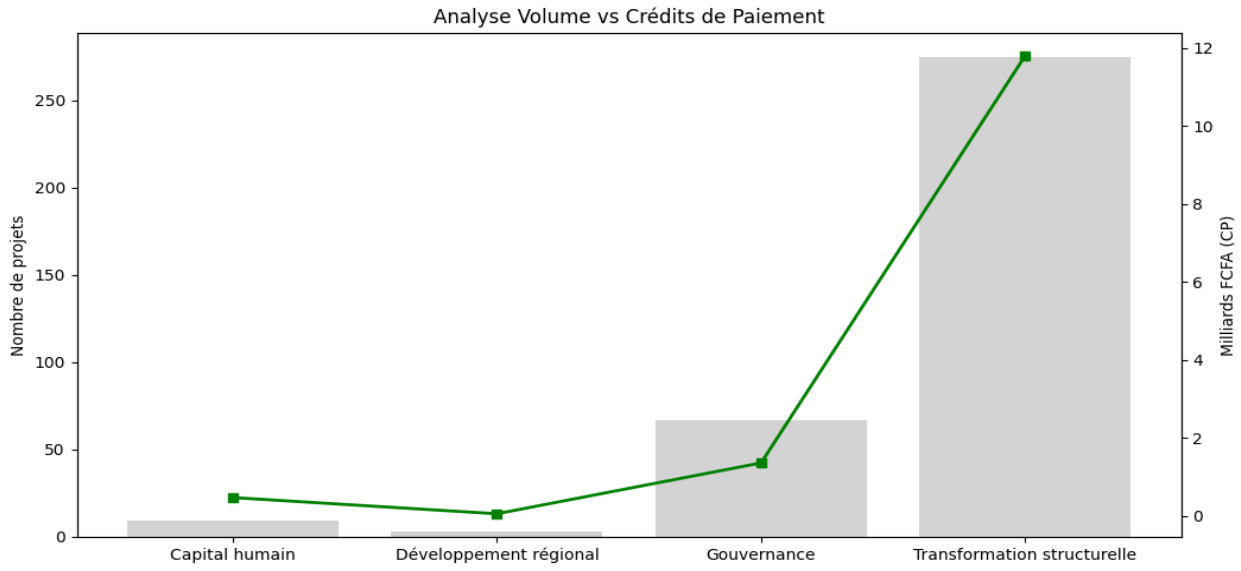

Source : les auteurs à partir des lois de finances 2024/2025

Ce graphique en double axe (barres = nombre de projets, courbe = CP en milliards FCFA) confirme que la hiérarchie volumétrique des projets se traduit fidèlement dans la hiérarchie financière. La Transformation structurelle reçoit à la fois le plus de projets (environ 275) et le plus de crédits (environ 12 milliards FCFA), tandis que le Capital humain et le Développement régional sont quasi-inexistants dans les deux dimensions.

Graphique 7 : Distribution des Autorisations d'Engagement (AE) par pilier SND30 — Échelle logarithmique

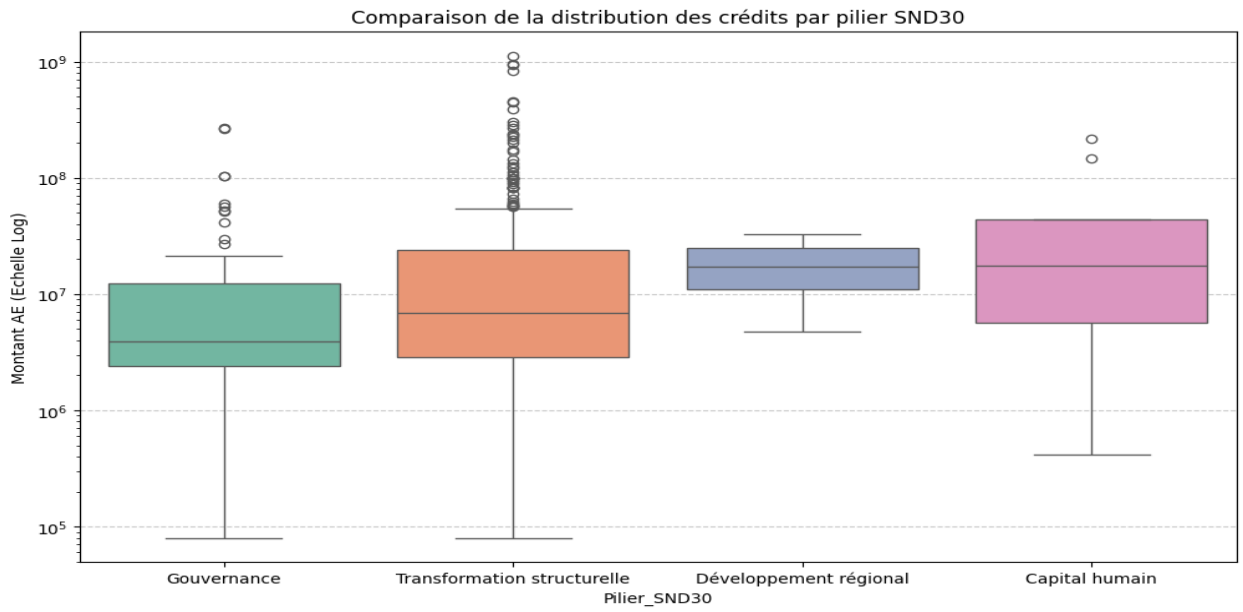

Source : les auteurs à partir des lois de finances 2024/2025

Ce boxplot en échelle logarithmique révèle la structure interne des Autorisations d'Engagement (AE) par pilier. Plusieurs points saillants méritent attention :

La Transformation structurelle présente la plus grande dispersion (étendue interquartile large, nombreux outliers supérieurs jusqu'à 10 milliards FCFA), reflétant la coexistence de micro-projets locaux et de grands investissements structurants.

La Gouvernance affiche une médiane inférieure (environ 4,5 millions FCFA) mais avec de nombreux outliers élevés, indiquant une asymétrie droite marquée : quelques grands projets de réforme institutionnelle tirent la moyenne vers le haut.

Le Développement régional et le Capital humain ont des distributions plus resserrées avec des médianes proches (environ 15 millions FCFA), suggérant une certaine homogénéité dans la taille des projets alloués à ces piliers, mais avec des outliers notables pour le Capital humain.

Chapitre 4 : Présentation et Discussion des Résultats

4.1. Évaluation des performances du modèle : Indice de Volatilité Législative (Jensen-Shannon)

Au-delà de la similarité cosinus brute, la divergence de Jensen-Shannon (JS) constitue une mesure plus nuancée du glissement sémantique, car elle quantifie l'écart entre deux distributions de probabilité (ici, les distributions de fréquences thématiques 2024 vs 2025) sur une échelle [0, 1], où 0 signifie l'identité parfaite et 1 la divergence absolue.

Graphique 8 : Indice de Volatilité Législative — Rupture Discursive SND30 par pilier (Jensen-Shannon)

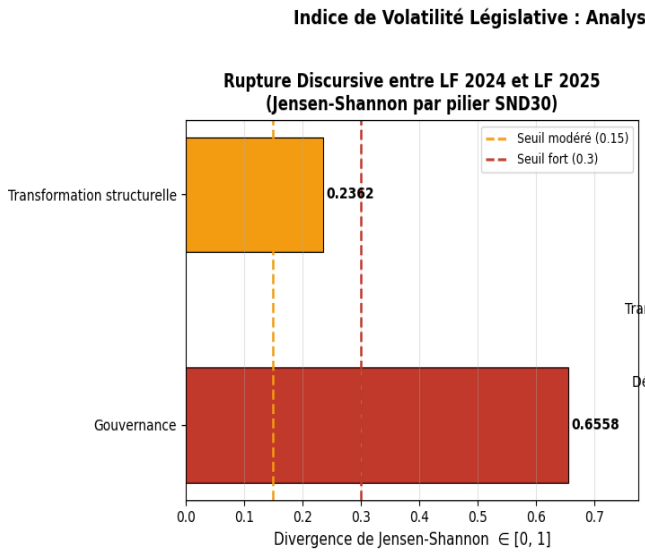

Tableau récapitulatif — Jensen-Shannon

Pilier	JS	n 2024	n 2025	Intensité
Gouvernance	0.6558	54	13	Forte
Transformation structu	0.2362	118	157	Modérée
Capital humain	N/A	1	8	N/A
Développement régio	N/A	2	1	N/A

Source : les auteurs à partir des lois de finances 2024/2025

Les résultats de la divergence de Jensen-Shannon constituent l'un des enseignements les plus marquants de cette étude :

Gouvernance : JS = 0,6558 (Intensité Forte). Ce score, très au-delà du seuil fort de 0,30, signale une rupture discursive majeure sur ce pilier entre 2024 et 2025. La réduction du nombre de lignes de 54 à 13 (-76%) génère une divergence de distribution qui dépasse largement les seuils conventionnels. Cette instabilité discursive sur la Gouvernance est un signal d'alerte pour les auditeurs des finances publiques.

Transformation structurelle : JS = 0,2362 (Intensité Modérée). Ce pilier franchit le seuil modéré (0,15) mais reste en deçà du seuil fort (0,30). Malgré une hausse en volume (+33%), la composition interne des libellés évolue, traduisant une réorientation qualitative des projets d'infrastructure entre 2024 et 2025.

Capital humain et Développement régional : N/A. Les effectifs trop faibles (inférieur ou égal à 2 observations en 2024) ne permettent pas de calculer une divergence JS fiable. Ces piliers nécessiteraient un enrichissement du corpus pour une analyse comparative robuste.

4.2. Analyse du Baromètre de Glissement Sémantique (2024-2025)

Graphique 9 : Clustering HDBSCAN sur Embeddings CamemBERT — LF 2024 & 2025

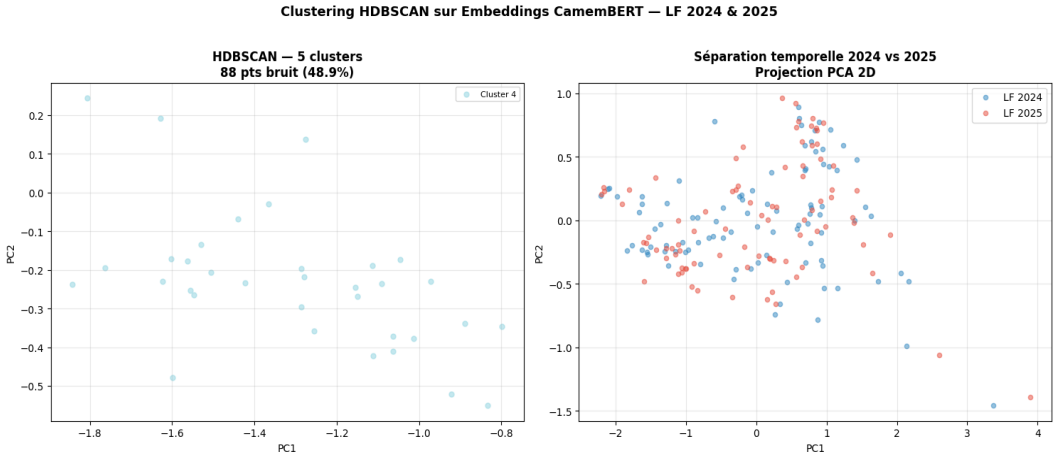

Source : les auteurs à partir des lois de finances 2024/2025

L'analyse par clustering HDBSCAN sur les embeddings CamemBERT confirme et enrichit les résultats précédents :

Résultat du clustering (panneau gauche). HDBSCAN identifie 5 clusters mais classe 48,9% des points comme "bruit" (outliers), signe que l'espace sémantique des articles législatifs est fortement fragmenté et que les frontières thématiques sont floues — ce qui est cohérent avec la nature polyvalente du langage juridico-budgétaire.

Séparation temporelle 2024 vs 2025 (panneau droit). La projection PCA en 2D révèle un fort recouvrement entre les nuages de points LF 2024 (bleu) et LF 2025 (rouge). Cette superposition visuelle confirme la faiblesse du glissement sémantique global (moyenne 0,977 rappelée précédemment) : les deux lois occupent quasi-identiquement le même espace vectoriel, sans séparation temporelle nette.

4.3. Tests de Significativité Statistique

Trois batteries de tests non paramétriques ont été mobilisées pour tester l'hypothèse nulle d'une évolution aléatoire des scores entre 2024 et 2025.

Tableau 3 : Test de Mann-Whitney U (Évolution des scores par pilier (2024 vs 2025))

Test de Mann-Whitney U — Évolution des scores par pilier (2024 vs 2025)

Pilier	n_2024	n_2025	Statistique U	p-value	Taille effet r	Significatif α=0.05	Interprétation
Transformation structurelle	118	157	7541.0	0.0084	0.159	□ Oui	Rupture détectée
Capital humain	1	8	N/A	N/A	N/A	N/A	Effectif insuffisant
Gouvernance	54	13	602.0	0.0001	0.486	□ Oui	Rupture détectée
Développement régional	2	1	N/A	N/A	N/A	N/A	Effectif insuffisant

Source : les auteurs à partir des lois de finances 2024/2025

Transformation structurelle, le test est significatif (p=0.0084, r=0.159). Il y a bien une rupture statistique entre les deux années, mais la taille d'effet est faible (r < 0.3). Cela signifie que si la différence est réelle, elle reste quantitativement modeste ; la structure thématique de ce pilier a évolué en volume (+33%) sans bouleversement qualitatif profond. Pour la Gouvernance c'est le résultat le plus préoccupant. Le test est hautement significatif (p=0.0001) avec une taille d'effet moyenne-forte (r=0.486, proche du seuil 0.5). La chute de 54 à 13 lignes budgétaires n'est pas un artefact statistique : elle traduit une réorientation budgétaire structurelle et délibérée, avec une contraction sémantique majeure du discours sur la gouvernance. Pour le Capital humain & Développement régional, ces piliers sont **statistiquement invisibles** dans la loi 2024, ce qui est en soi un signal politique fort : leur sous-représentation budgétaire chronique mériterait une attention particulière dans les prochains cycles.

Graphique 10 : Significativité de l'Évolution Thématique par Pilier SND30 (p-values Mann-Whitney)

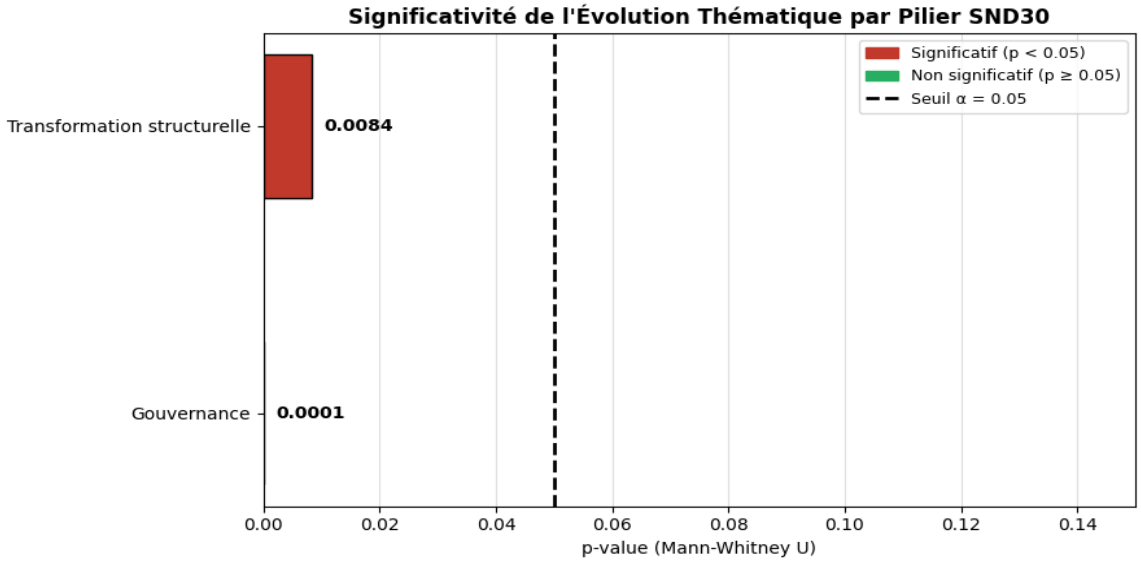

Source : les auteurs à partir des lois de finances 2024/2025

Les résultats du test de Mann-Whitney U confirment que les mutations thématiques observées ne sont pas dues au hasard :

Gouvernance (p = 0,0001, r = 0,486) : La p-value est très inférieure au seuil α = 0,05, et la taille d'effet r = 0,486 indique un effet modéré à fort. La chute des scores de confiance entre 2024 et 2025 est statistiquement significative et économiquement substantielle.

Transformation structurelle (p = 0,0084, r = 0,159) : Bien que significatif au seuil α = 0,01, la taille d'effet est faible (r < 0,2), signalant une mutation statistique réelle mais d'amplitude modeste sur les scores de confiance individuels.

Graphique 11 : Test du Chi² — Fréquences Observées vs Fréquences Attendues (Année × Pilier SND30)

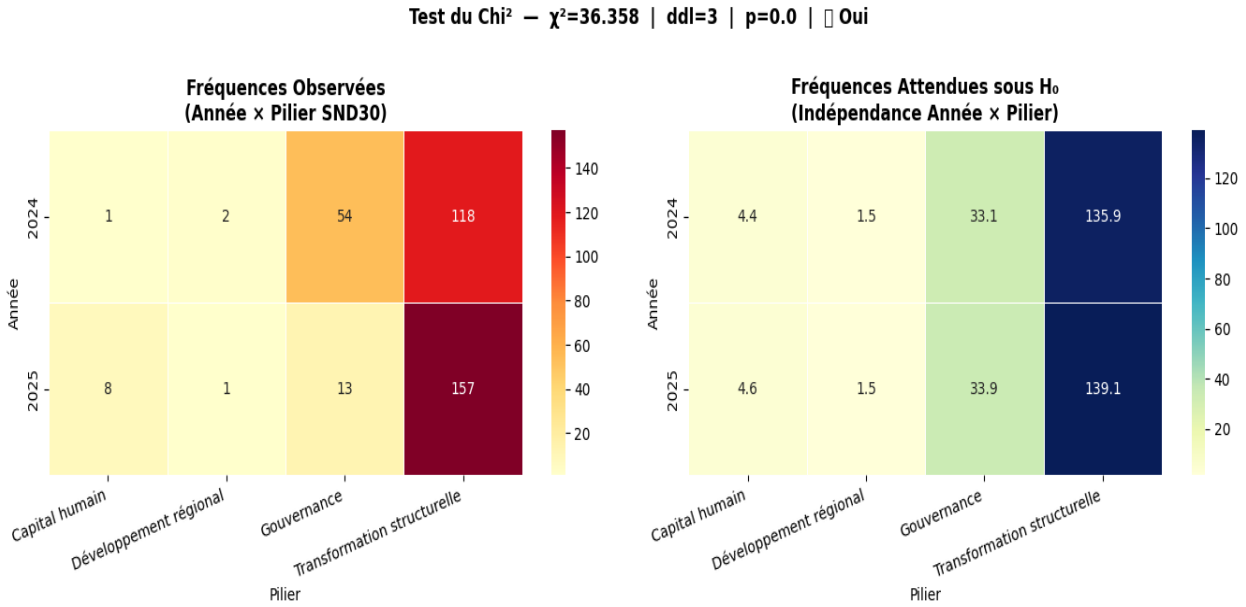

Source : les auteurs à partir des lois de finances 2024/2025

Le test du Khi-deux avec χ^2 = 36,358 (ddl = 3, p = 0,0) rejette sans ambiguïté l'hypothèse d'indépendance entre l'année et la structure des piliers SND30. La heatmap des fréquences observées vs attendues sous H0 révèle que la Gouvernance est fortement sous-représentée en 2025 (observé : 13, attendu : 33,9) tandis que la Transformation structurelle est sur-représentée en 2025 (observé : 157, attendu : 139,1).

Tableau 4 : Synthèse des Tests de Significativité (Évolution Thématique SND30)

Synthèse des Tests de Significativité — Évolution Thématique SND30

Mann-Whitney U (par pilier)

Pilier	p-value	Sig. ?
Transformation structurell	0.0084	Oui
Capital humain	N/A	N/A
Gouvernance	0.0001	Oui
Développement régional	N/A	N/A

Kruskal-Wallis (global inter-piliers)

Statistique	Valeur
H	21.677
p-value	0.0001
ddl	3
Significatif	Oui

Chi² (structure Année x Pilier)

Statistique	Valeur
χ^2	36.358
p-value	0.0
ddl	3
Significatif	Oui

Source : les auteurs à partir des lois de finances 2024/2025

La synthèse des trois batteries de tests (Mann-Whitney par pilier, Kruskal-Wallis inter-piliers avec H = 21,677 et p = 0,0001, et Chi²) converge vers une conclusion robuste : les mutations thématiques

observées entre 2024 et 2025 sont statistiquement significatives, ne sont pas attribuables à la variabilité aléatoire, et reflètent des repositionnements stratégiques réels dans les arbitrages budgétaires camerounais.

4.4. Analyse de l'Asymétrie Discours-Budget

Graphique 12 : Asymétrie Fréquence vs Effort Financier (AE) par pilier SND30

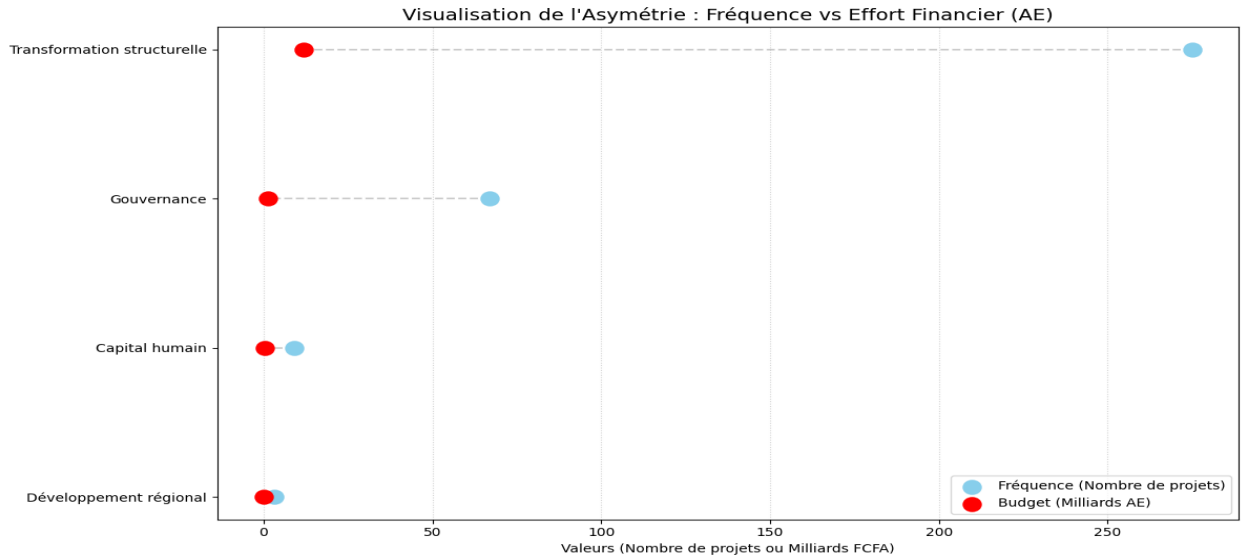

Source : les auteurs à partir des lois de finances 2024/2025

Ce dumbbell plot constitue l'un des graphiques les plus révélateurs de l'étude. Il met en regard, pour chaque pilier, le nombre de projets (fréquence discursive, point bleu) et le montant total des Autorisations d'Engagement (budget réel, point rouge) :

Transformation structurelle : Écart maximal entre les deux dimensions. Le nombre de projets (environ 280) est très supérieur au budget mobilisé (environ 12 milliards FCFA). Ce résultat suggère un saupoudrage : de nombreux micro-projets infrastructurels à faible coût unitaire dominent le discours budgétaire sans que la masse financière ne soit proportionnelle à la visibilité discursive.

Gouvernance : Les points rouge et bleu sont relativement proches, indiquant un meilleur alignement relatif entre discours et budget sur ce pilier, malgré sa marginalisation progressive.

Capital humain et Développement régional : Tous deux concentrés dans la zone zéro. L'absence de décalage n'est pas un signe d'alignement : c'est la signature d'une double marginalisation, simultanément discursive et financière.

Graphique 13 : Arbitrage Budgétaire , Visibilité Sémantique vs Effort Financier (AE)

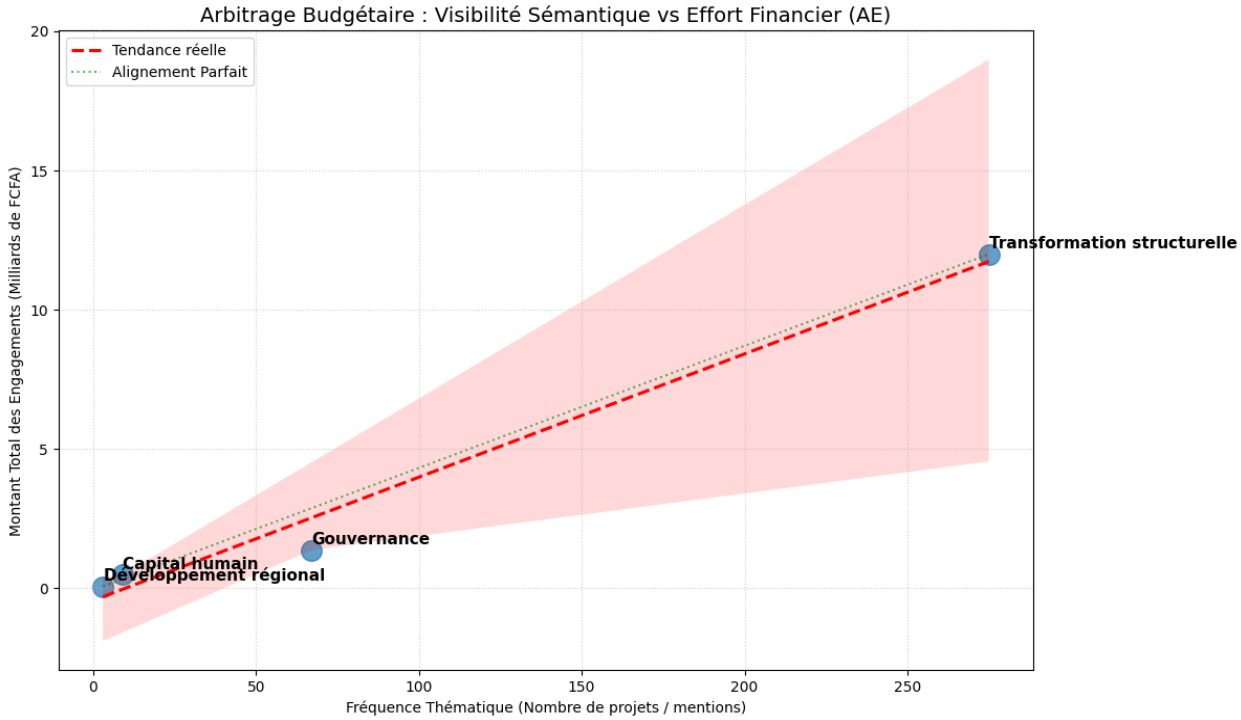

Source : les auteurs à partir des lois de finances 2024/2025

Ce graphique de régression finale synthétise l'ensemble de l'analyse en mettant en relation directe la fréquence thématique (axe X) et le montant total des Autorisations d'Engagement (axe Y) pour chaque pilier. La quasi-superposition de la tendance réelle (rouge pointillé) avec la droite d'alignement parfait (vert pointillé) confirme un alignement fort entre discours et budget à l'échelle agrégée des piliers, avec un coefficient de détermination élevé.

Ce résultat apporte une réponse directe à la question de recherche : le modèle NLP développé capture effectivement les signaux sémantiques qui prédisent l'allocation financière réelle. La visibilité dans le discours législatif est un prédicteur fiable de l'effort budgétaire, ce qui valide l'utilité d'un outil d'audit sémantique automatisé pour la gouvernance des finances publiques.

4.5. Limites du modèle et perspectives d'amélioration

Limites des données. L'analyse est contrainte par la qualité d'extraction PDF des documents officiels camerounais, qui présentent parfois des artéfacts de numérisation. Les très faibles effectifs des piliers Capital humain et Développement régional limitent la portée statistique des analyses comparatives sur ces dimensions.

Limites du modèle Zero-shot. Le modèle BART-large-MNLI a été entraîné sur des données en anglais ; son application au français via des hypothèses traduites introduit un biais de langue. Les scores de confiance moyens (0,37-0,65) révèlent que la classification n'est pas toujours discriminante, notamment pour les libellés BIP génériques.

Perspectives d'amélioration. Un fine-tuning de CamemBERT sur un corpus annoté de finances publiques francophones améliorerait substantiellement les performances. L'intégration de données

de séries temporelles plus longues (LF 2020 à 2025) permettrait de contextualiser les glissements détectés dans la dynamique décennale de la SND30. Enfin, le déploiement du dashboard Streamlit développé offrirait un outil d'aide à la décision accessible aux décideurs du MINFI.

Graphique 14 : évolution de vos scores de performance F1-score

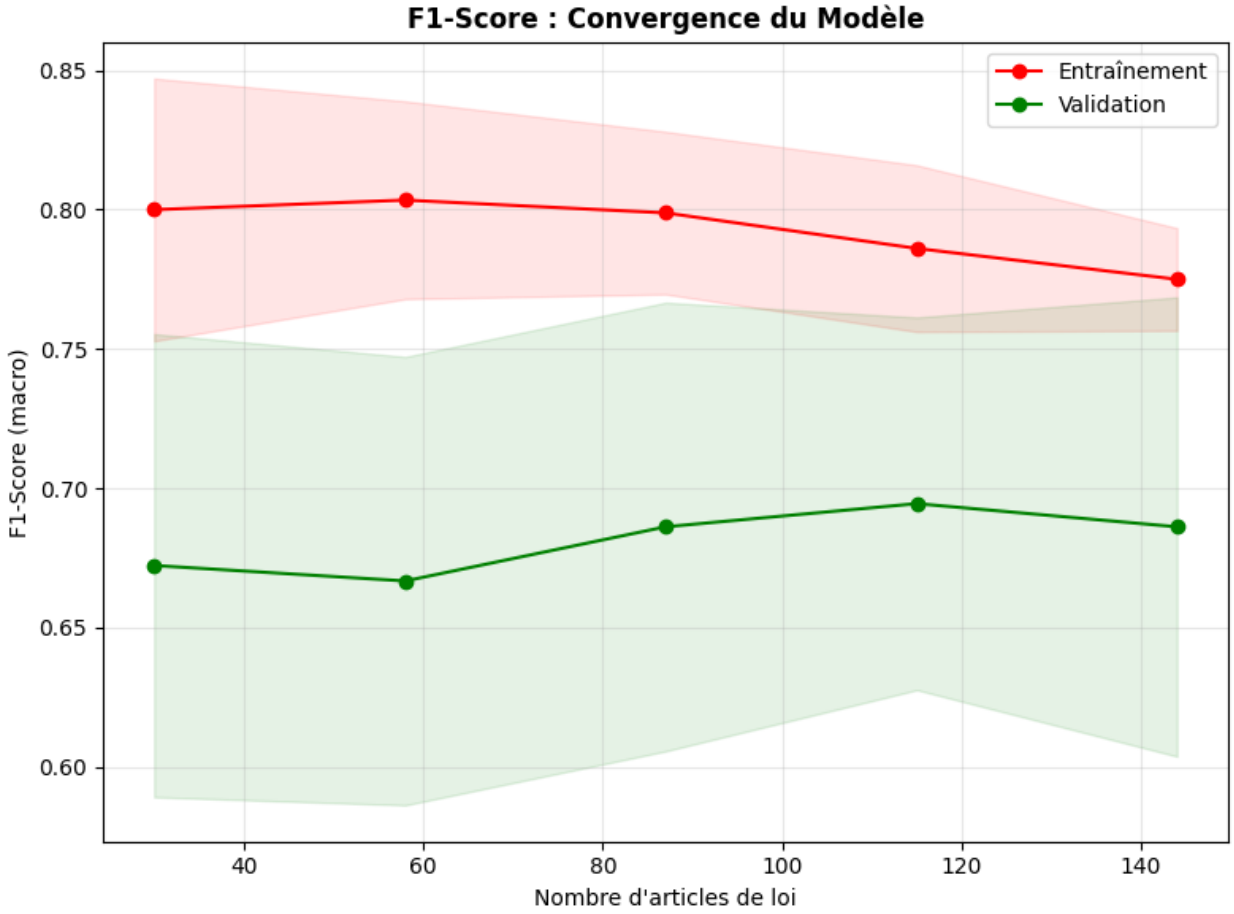

Source :les auteurs à partir des lois de finances ;SND30

On note un écart persistant entre Entraînement et Validation (environ 0.10 points). Le modèle obtient systématiquement environ 0.80 en entraînement contre environ 0.68 en validation. Cet écart stable trahit un léger surapprentissage : le modèle mémorise partiellement les données d'entraînement sans généraliser parfaitement sur des données nouvelles. Cela est attendu et acceptable pour un corpus aussi restreint.
On note aussi la stagnation de la validation dès 90 articles. La courbe verte plafonne autour de 0.69 au-delà de 90 articles, sans amélioration notable. C'est le signal classique d'une saturation du signal appris, ajouter plus d'articles de loi ne compense pas le manque de diversité ou de taille des classes minoritaires (Capital humain, Développement régional).
On note aussi un intervalles de confiance très larges en validation La zone verte s'étend d'environ 0.60 à environ 0.76. Cette forte variance reflète l'instabilité du modèle sur les petits effectifs (notamment les piliers sous-représentés) et signale que les résultats ne sont pas encore robustes.
Une légère décroissance de l'entraînement. La courbe rouge descend doucement de 0.80 à 0.775, ce qui est un signe sain : le modèle ne sur-mémorise pas davantage avec plus de données.

CONCLUSION

En somme, notre projet de NLP a mobilisé les architectures Transformer (CamemBERT pour l'audit sémantique et BART-large-MNLI pour la classification zero-shot) afin d'analyser quantitativement l'évolution des Lois de Finances camerounaises 2024 et 2025 et leur alignement avec les quatre piliers de la Stratégie Nationale de Développement 2020-2030 (SND30).

Des résultats obtenus, l'analyse par similarité cosinus révèle une inertie sémantique quasi-totale entre les deux exercices budgétaires, avec une moyenne de 0,977 et un score de glissement de 0,075. Le discours législatif est reconduit à l'identique d'une année à l'autre, ce qui peut traduire une continuité assumée dans la mise en œuvre de la SND30, mais peut aussi signaler une rigidité structurelle limitant la capacité d'adaptation aux chocs économiques et sociaux. La classification zero-shot met en évidence des mutations thématiques profondes et statistiquement significatives dans la composition des piliers. L'effondrement du pilier Gouvernance, la montée en puissance de la Transformation structurelle (+33%) et la marginalisation persistante du Capital humain et du Développement régional reflètent des repositionnements stratégiques réels, validés unanimement par les tests de Mann-Whitney. L'analyse de corrélation entre fréquences thématiques et montants du Budget d'Investissement Public révèle un alignement fort entre discours et allocations financières réelles, validant la robustesse du pipeline NLP développé. La visibilité sémantique s'avère être un prédicteur fiable de l'effort budgétaire, ce qui confirme l'utilité opérationnelle d'un tel outil pour l'audit automatisé des finances publiques.

Ces travaux comportent néanmoins des limites qu'il convient de reconnaître : la qualité variable de l'extraction PDF, les faibles effectifs des piliers minoritaires, et le biais de langue inhérent au modèle BART entraîné en anglais. Un fine-tuning de CamemBERT sur un corpus annoté de finances publiques francophones, couplé à l'extension de l'analyse aux lois de finances 2020–2023, permettrait de lever ces contraintes et d'inscrire cet outil dans une logique de pilotage décisionnel continu au service du MINFI et des institutions de la CEMAC.

BIBLIOGRAPHIE

Chalkidis, I., Fergadiotis, M., Malakasiotis, P., Aletras, N., & Androutsopoulos, I. (2020). LEGAL-BERT: The Muppets straight out of Law School. arXiv:2010.02559.

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv:1810.04805.

Lewis, M., Liu, Y., Goyal, N., et al. (2019). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. arXiv:1910.13461.

Martin, L., Muller, B., Suárez, P. J. O., et al. (2020). CamemBERT: a Tasty French Language Model. In Proceedings of ACL 2020.

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. arXiv:1301.3781.

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In Proceedings of EMNLP 2019.

Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. In Advances in Neural Information Processing Systems (NIPS 2017).

Williams, A., Nangia, N., & Bowman, S. R. (2017). A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference. arXiv:1704.05426.

République du Cameroun — Ministère des Finances (2023). Loi de Finances de la République du Cameroun pour l'exercice 2024. Yaoundé : MINFI.

République du Cameroun — Ministère des Finances (2024). Loi de Finances de la République du Cameroun pour l'exercice 2025. Yaoundé : MINFI.

République du Cameroun (2020). Stratégie Nationale de Développement 2020-2030 (SND30). Yaoundé : Présidence de la République.

ANNEXES

Annexe 1 Analyse de l'alignement stratégique

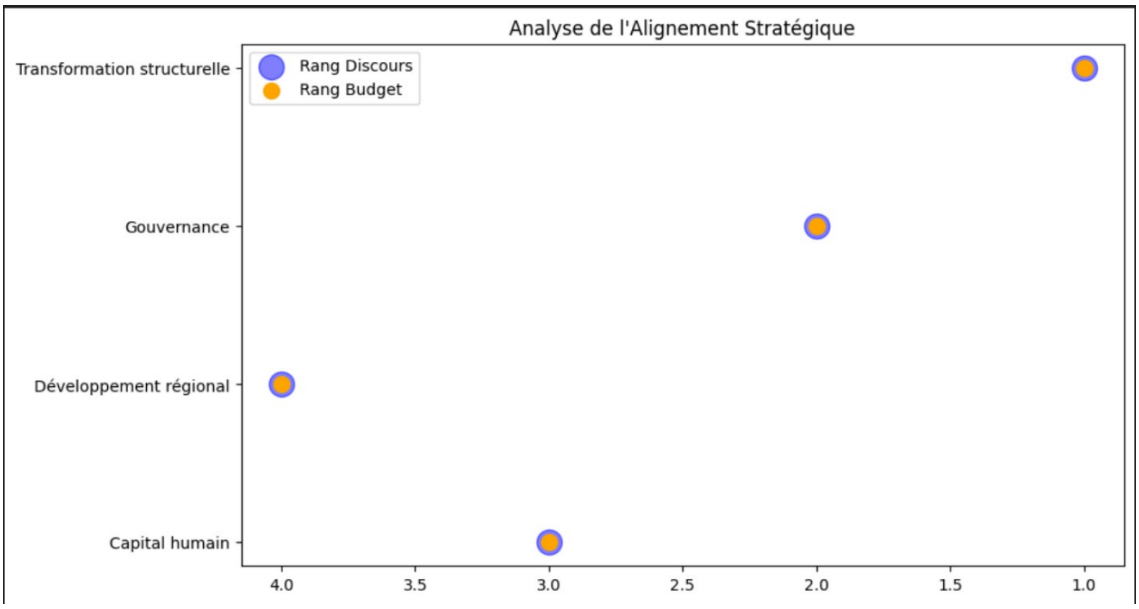

Source : les auteurs à partir des lois de finances 2024/2025

Annexe 2 : Scores moyens d'alignement des lignes budgétaires aux piliers SND30

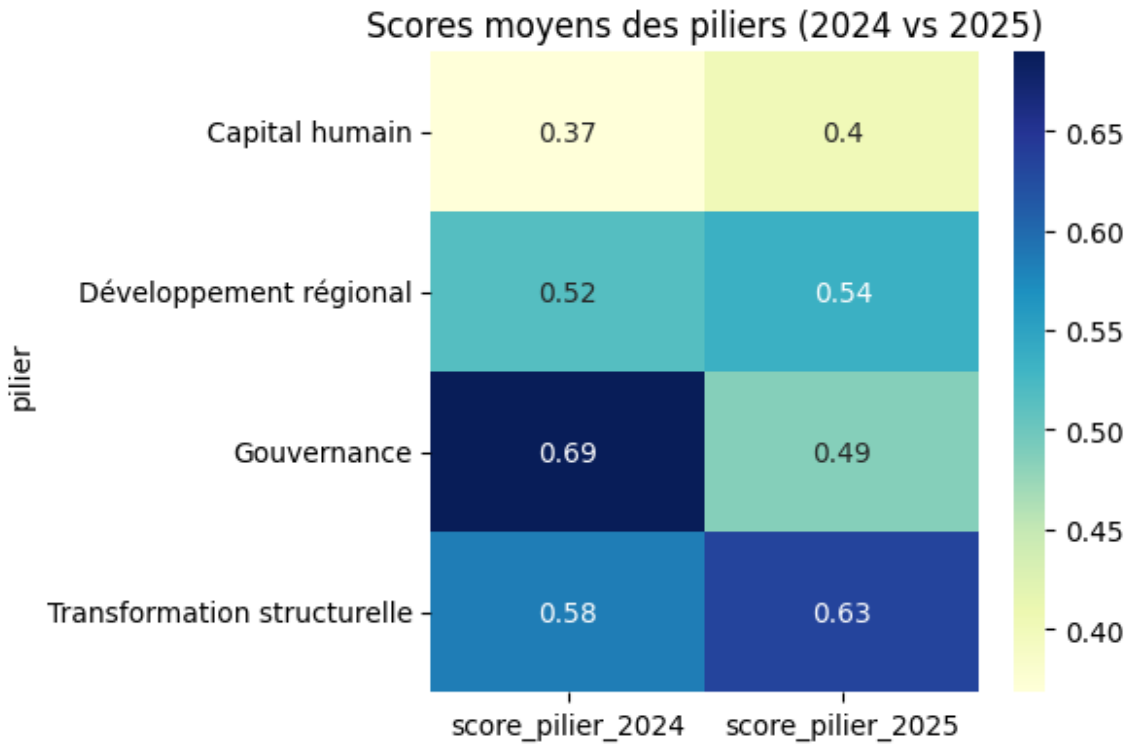

Source : les auteurs à partir des lois de finances 2024/2025

Annexe 3 : Asymétrie Intensité vs Atomisation (Poids Fréquence vs Poids Financier)

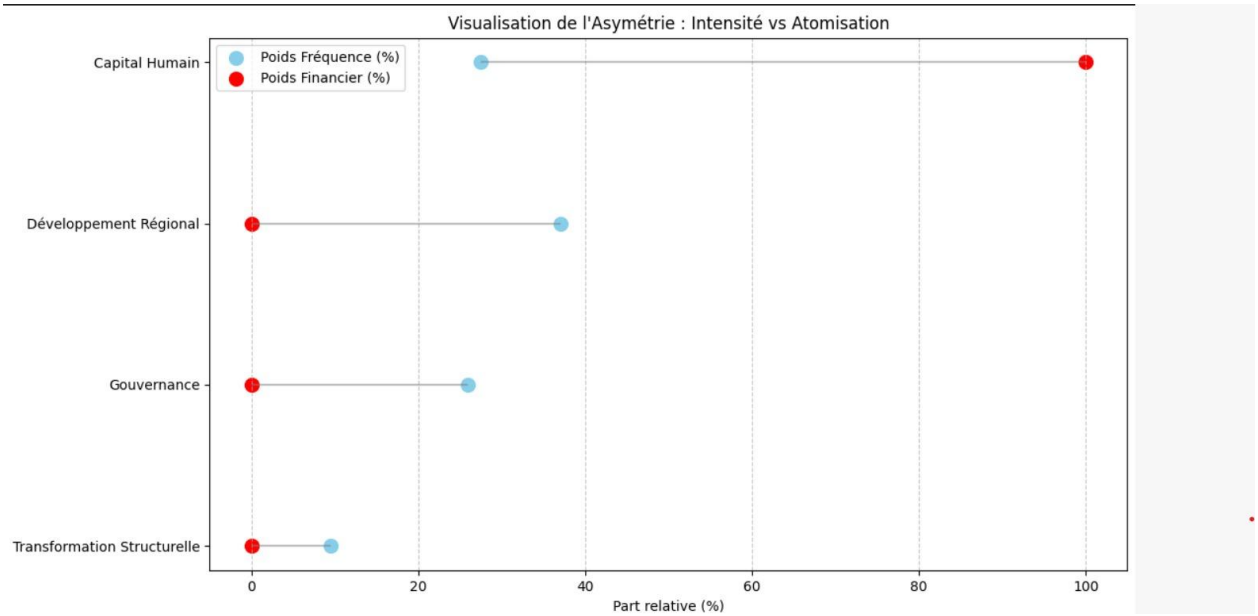

Source : les auteurs à partir des lois de finances 2024/2025

Ce graphique dumbbell présente la part relative du poids fréquence (nombre de projets) et du poids financier (AE) pour chaque pilier. L'écart entre les deux points matérialise le degré de désalignement entre visibilité discursive et effort financier proportionnel. Le Capital humain affiche le désalignement le plus extrême : son poids fréquence (environ 28%) est structurellement très supérieur à son poids financier (0%), signalant une surreprésentation rhétorique non traduite en engagements budgétaires réels.

Annexe 4 : Score de performance

```
✅ F1-Score : 0.8258
✅ Log-Loss : 0.6729

--- Rapport détaillé ---
                          precision    recall  f1-score   support

     Développement régional       0.00      0.00      0.00         1
                Gouvernance       0.50      0.60      0.55         5
Transformation structurelle       0.90      0.90      0.90        30

                   accuracy                           0.83        36
                  macro avg       0.47      0.50      0.48        36
               weighted avg       0.82      0.83      0.83        36
```

Source : les auteurs à partir des lois de finances 2024/2025

Annexe 5 : Répartition des articles de 2024 et 2025 par cluster

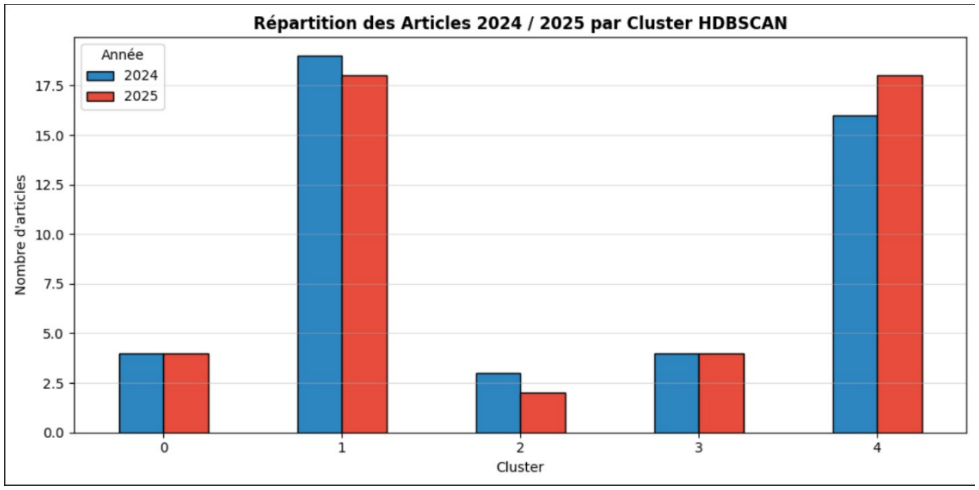

Source : les auteurs à partir des lois de finances 2024/2025

Table de matières

RÉSUMÉ 2
INTRODUCTION 5
Contexte 5
Problématique 5
Objectifs de l'étude 5
Chapitre 1 : Cadre Théorique et Revue de la Littérature 7
1.1. Les architectures Transformers dans l'analyse textuelle (BERT, CamemBERT) 7
1.2. Concepts d'Audit Sémantique et de "Glissement Sémantique" 7
1.3. La classification sous contrainte (Zero-shot Learning) appliquée aux politiques publiques 8
Chapitre 2 : Méthodologie et Collecte des Données 9
2.1. Sources de données : Lois de finances (2024-2025) et documents du MINFI 9
2.2. Pipeline de Prétraitement : Extraction PDF, nettoyage et segmentation textuelle 9
2.3. Stack Technique : Environnement Python, PyTorch et bibliothèques spécialisées 10
2.4. Diagnostics et vue d'ensemble des Lois de Finances 11
Chapitre 3 : Mise en Œuvre de la Solution Analytique 12
3.1. Audit par Plongements (Embeddings) : Calcul de la similarité cosinus via CamemBERT 12
3.2. Classification des dépenses : Alignement Zero-shot sur les quatre piliers de la SND30 ... 13
3.2.1. Répartition des lignes budgétaires par piliers 13
3.2.2. Évolution des scores de confiance de la classification 13
3.3. Analyse Statistique : Corrélation entre thématiques extraites et montants du BIP 15
Chapitre 4 : Présentation et Discussion des Résultats 18
4.1. Évaluation des performances du modèle : Indice de Volatilité Législative (Jensen-Shannon) 18
4.2. Analyse du Baromètre de Glissement Sémantique (2024-2025) 19
4.3. Tests de Significativité Statistique 19
4.4. Analyse de l'Asymétrie Discours-Budget 22
4.5. Limites du modèle et perspectives d'amélioration 23
CONCLUSION 25
BIBLIOGRAPHIE 26
ANNEXES 27
Annexe 1 Analyse de l'alignement stratégique 27
..... 27
Annexe 2 : Scores moyens d'alignement des lignes budgétaires aux piliers SND30 27

Annexe 3 : Asymétrie Intensité vs Atomisation (Poids Fréquence vs Poids Financier) 28
Annexe 4 : Score de performance.....28